

Analisi delle Prestazioni di Modelli Centralizzati ILP per il Task Routing al variare della Deadline

Claudio Bagini 2045337

20 luglio 2026

1 Introduzione

Nel contesto dei sistemi distribuiti moderni e dell'edge computing, l'allocazione efficiente delle risorse computazionali (Resource Allocation) e l'istadamento dei task (Task Routing) rappresentano sfide critiche e di primaria importanza.

Il sistema analizzato in questo studio sfrutta un approccio centralizzato basato su Integer Linear Programming (ILP) per mappare le richieste in ingresso sui nodi server disponibili. A differenza delle euristiche, che compiono scelte ottime a livello puramente locale (ma spesso sub-ottime a livello globale), il modello ILP garantisce l'individuazione di una soluzione matematicamente perfetta per un dato set di richieste.

Per comprendere a fondo l'impatto delle policy di orchestrazione e il comportamento del solutore centralizzato sotto stress, il modello è stato testato imponendo due diverse strategie di mappatura (*Objective Mapping*) nella funzione obiettivo:

- **Mapping Time:** I pesi della funzione obiettivo privilegiano la minimizzazione del tempo totale di risposta e di trasmissione ($W_{lat} = 1, W_{en} = 0$). Questa strategia è cruciale per i servizi altamente sensibili al ritardo (delay-sensitive).
- **Mapping Energy:** I pesi della funzione obiettivo privilegiano il risparmio energetico dei nodi e della rete ($W_{lat} = 0, W_{en} = 1$), parametro fondamentale per estendere la vita operativa di infrastrutture con rigidi vincoli di power-budget.

Le simulazioni mirano a individuare i colli di bottiglia fisici e logici del sistema e a valutare quali configurazioni di *Batch Size* (dimensione della coda di richieste aggregata) e *Batch Timeout* (tempo massimo di attesa prima di innescare l'ILP) garantiscano la maggiore resilienza al variare del tasso di arrivo delle richieste nella rete.

2 Setup Sperimentale

Le simulazioni sono state eseguite mantenendo un set di parametri di base costanti (ispirati al paper ICDCS di riferimento), al fine di isolare l'impatto delle metriche di interesse.

2.1 Parametri e Variabili dell'Esperimento

- **Budget Energetico Globale:** Fissato rigorosamente a 80 KJ per l'intera durata di ogni iterazione di simulazione.
- **Arrival Rate (Carico di Rete):** Variabile indipendente principale. Il tasso di arrivo delle richieste è stato modulato per simulare scenari di traffico progressivo: da 2, 3, 4, 6, 8 fino a 10 richieste al secondo. Nel motore del simulatore, questi valori corrispondono a tempi di inter-arrivo (AT) decrescenti (da 0.5 a 0.1 secondi).

- **Configurazioni di Batching:** Per ogni livello di *Arrival Rate*, sono state testate molteplici configurazioni incrociate. Variando la *Batch Size* (BS), si è stabilito quante richieste accumulare prima di avviare il solutore ILP (da 1 a 20). Variando il *Batch Timeout* (BT), si è imposto un limite temporale massimo per prevenire lo stallo delle richieste (starvation) in scenari di traffico rado.
- **Coefficienti di Ponderazione (α, β, γ):** In stretta conformità con il modello matematico del paper di riferimento, i vettori dei pesi che regolano i trade-off e i costi delle risorse all'interno della formulazione ILP sono stati mantenuti costanti, garantendo la coerenza dell'esperimento. Nello specifico, i parametri di profilazione sono stati fissati ai seguenti valori vettoriali: $\alpha = (0.3, 0.5, 0.2)$, $\beta = (0.4, 0.35, 0.25)$ e $\gamma = (0.7, 0.3)$.
- **Rilassamento della Deadline:** In questa serie di esperimenti, il vincolo temporale imposto sui task è stato progressivamente allentato, testando un delta incrementale del 10%, 20% e 30% rispetto al valore di base.

3 Migliorie e Correzioni Apportate

In questa sezione vengono illustrate sinteticamente le principali modifiche apportate al simulatore.

- **Modifica della formula per il calcolo della deadline:** È stata introdotta una differenziazione logica nel calcolo della deadline assegnata ai task per tenere conto della latenza di raggruppamento. La nuova formulazione del vincolo temporale D_r è così definita:

$$D_r = \begin{cases} (1.0 + \Delta_D) \cdot (d_{cpu} + d_{net} + d_{down} + \frac{1}{2}T_{batch}) & \text{con orchestratore} \\ (1.0 + \Delta_D) \cdot (d_{cpu} + d_{net} + d_{down}) & \text{senza orchestratore} \end{cases} \quad (1)$$

dove Δ_D rappresenta l'incremento percentuale tollerato, mentre T_{batch} indica il parametro di `centralized_batch_timeout`. Questa correzione assicura che il tempo trascorso in attesa della risoluzione del routing non consumi in modo sproporzionato il margine temporale utile del task.

4 Configurazione Energy

4.1 Success Rate




Figura 1: Scomposizione del Success Rate (DL = 10%).




Figura 2: Scomposizione del Success Rate (DL = 20%).




Figura 3: Scomposizione del Success Rate (DL = 30%).

Come si evince dai grafici di Figura 1, 2 e 3, un incremento del parametro di rilassamento della deadline non produce, in generale, un aumento significativo del tasso di successo delle richieste. Tuttavia, in specifiche configurazioni si registra un lieve miglioramento prestazionale. Spicca, in particolare, l'impostazione con $BS = 20$ e $BT = 0.0$, che mostra una crescita del tasso di successo di circa il 10% passando da $DL = 10\%$ a $DL = 30\%$. Risulta invece anomalo il divario prestazionale della configurazione con $BS = 1$ e $BT = 2.0$, la quale presenta un tasso di successo nettamente inferiore rispetto al caso $BS = 20$ e $BT = 0.0$. L'ipotesi più plausibile per spiegare tale comportamento è da ricercarsi nelle dinamiche interne di gestione degli eventi da parte dell'ambiente SimPy.

4.2 Rejection Reasons




Figura 4: Scomposizione del Rejection Reasons (DL = 10%).




Figura 5: Scomposizione del Rejection Reasons (DL = 20%).




Figura 6: Scomposizione del Rejection Reasons (DL = 30%).

L'analisi delle Figure 4, 5 e 6 mostra come l'incremento del parametro di rilassamento della deadline (DL) alteri significativamente la distribuzione delle cause di reiezione. Nello specifico, passando da un DL del 10% al 30%, diminuiscono i fallimenti per superamento del limite temporale (*Deadline exceeded*), grazie al maggior margine a disposizione per l'allocazione.

Tuttavia, tale riduzione è interamente compensata da un proporzionale aumento delle reiezioni per esaurimento capacitivo (*Insuff. CPU* e *Insuff. CPU/NET*): trattenendo le richieste nel sistema per un tempo maggiore, si accelera infatti la saturazione delle risorse fisiche. Infine, all'aumentare del carico (*Arrival Rate*), la carenza infrastrutturale si consolida strutturalmente come il principale collo di bottiglia del sistema, scavalcando i limiti imposti dalla latenza.

4.3 Response Time




Figura 7: Scomposizione del Response Time (DL = 10%).




Figura 8: Scomposizione del Response Time (DL = 20%).




Figura 9: Scomposizione del Response Time (DL = 30%).

Come si evince dall'analisi delle Figure 7, 8 e 9, relative all'andamento dei tempi di risposta, un incremento del carico di richieste (*Arrival Rate*) produce un prevedibile innalzamento delle latenze complessive. La scomposizione del grafico a barre impilate evidenzia chiaramente come il tempo totale sia ampiamente dominato dalla componente di rete (*Network/Wait Time*, porzione superiore sbiadita), mentre i tempi di elaborazione vera e propria del sistema (*System Execution*, porzione inferiore solida) si mantengano marginali e pressoché costanti.

Infine, la variazione del rilassamento della deadline (DL dal 10% al 30%) non altera in modo sostanziale queste dinamiche.

5 Configurazione Time

La variazione dei risultati sperimentali tra le 2 configurazioni di *Objective Mapping* (Energy vs Time) è stata sorprendentemente minima. In generale, la configurazione *Mapping Time* ha mostrato un leggero miglioramento del tasso di successo delle richieste, con una riduzione del tempo medio di risposta. Tuttavia, le differenze non sono state così marcate da giustificare un cambiamento radicale nella strategia di mappatura.

5.1 Success Rate




Figura 10: Scomposizione del Success Rate (DL = 10%).




Figura 11: Scomposizione del Success Rate (DL = 20%).




Figura 12: Scomposizione del Success Rate (DL = 30%).

5.2 Rejection Reasons




Figura 13: Scomposizione del Rejection Reasons (DL = 10%).




Figura 14: Scomposizione del Rejection Reasons (DL = 20%).




Figura 15: Scomposizione del Rejection Reasons (DL = 30%).

5.3 Response Time




Figura 16: Scomposizione del Response Time (DL = 10%).




Figura 17: Scomposizione del Response Time (DL = 20%).




Figura 18: Scomposizione del Response Time (DL = 30%).

6 Dati Sperimentali

Tabella 1: Risultati medi aggregati per Deadline, Batch Size (BS), Batch Timeout (BT) e Tasso di Arrivo.

DL (%)	BS	BT	Arr. Rate (req/sec)	Succ. Rate (%)	Resp. Time (ms)	Exec. Time (ms)
10	1	2.0	2	73.85	0.354	0.136
10	1	2.0	3	69.65	0.437	0.169
10	1	2.0	4	65.13	0.446	0.171
10	1	2.0	6	57.93	0.575	0.228
10	1	2.0	8	55.48	0.598	0.234
10	1	2.0	10	52.83	0.637	0.249
10	2	2.0	2	71.38	0.548	0.234
10	2	2.0	3	70.39	0.623	0.263
10	2	2.0	4	63.37	0.617	0.256
10	2	2.0	6	54.56	0.670	0.274
10	2	2.0	8	53.99	0.708	0.288
10	2	2.0	10	51.66	0.738	0.298
10	4	2.0	2	58.86	0.849	0.385
10	4	2.0	3	60.02	0.887	0.394
10	4	2.0	4	58.61	0.900	0.394
10	4	2.0	6	53.29	0.911	0.393
10	4	2.0	8	50.94	0.913	0.390
10	4	2.0	10	48.36	0.890	0.374
10	6	2.0	2	52.16	1.059	0.491
10	6	2.0	3	51.36	1.032	0.469

Continua nella pagina successiva...

Tabella 1 – continua dalla pagina precedente

DL (%)	BS	BT	Arr. Rate (req/sec)	Succ. Rate (%)	Resp. Time (ms)	Exec. Time (ms)
10	6	2.0	4	50.51	1.117	0.506
10	6	2.0	6	50.48	1.090	0.486
10	6	2.0	8	48.72	1.066	0.467
10	6	2.0	10	46.43	1.024	0.444
10	8	2.0	2	49.62	1.096	0.510
10	8	2.0	3	46.19	1.178	0.544
10	8	2.0	4	45.18	1.167	0.533
10	8	2.0	6	47.81	1.282	0.577
10	8	2.0	8	47.81	1.241	0.551
10	8	2.0	10	47.27	1.210	0.531
10	10	2.0	2	49.36	1.139	0.532
10	10	2.0	3	43.04	1.198	0.553
10	10	2.0	4	41.24	1.272	0.585
10	10	2.0	6	42.22	1.385	0.629
10	10	2.0	8	44.20	1.428	0.641
10	10	2.0	10	46.06	1.383	0.612
10	20	0.0	2	93.80	0.469	0.179
10	20	0.0	3	91.84	0.483	0.181
10	20	0.0	4	89.37	0.536	0.201
10	20	0.0	6	67.61	0.621	0.235
10	20	0.0	8	53.35	0.682	0.262
10	20	0.0	10	41.88	0.747	0.291
10	20	0.05	2	76.38	0.591	0.242
10	20	0.05	3	72.90	0.613	0.248
10	20	0.05	4	71.45	0.678	0.273
10	20	0.05	6	67.14	0.730	0.293
10	20	0.05	8	54.39	0.775	0.310
10	20	0.05	10	41.66	0.824	0.330
10	20	0.1	2	66.39	0.707	0.301
10	20	0.1	3	63.75	0.745	0.315
10	20	0.1	4	62.32	0.776	0.325
10	20	0.1	6	59.83	0.831	0.345
10	20	0.1	8	52.82	0.872	0.361
10	20	0.1	10	41.95	0.907	0.374
10	20	0.2	2	58.08	0.798	0.352
10	20	0.2	3	55.17	0.863	0.376
10	20	0.2	4	53.94	0.898	0.388
10	20	0.2	6	51.34	0.964	0.414
10	20	0.2	8	50.06	0.984	0.419
10	20	0.2	10	42.28	1.032	0.439
10	20	0.4	2	53.26	0.899	0.405
10	20	0.4	3	49.12	0.966	0.431
10	20	0.4	4	48.25	1.021	0.453
10	20	0.4	6	45.52	1.090	0.478

Continua nella pagina successiva...

Tabella 1 – continua dalla pagina precedente

DL (%)	BS	BT	Arr. Rate (req/sec)	Succ. Rate (%)	Resp. Time (ms)	Exec. Time (ms)
10	20	0.4	8	44.11	1.126	0.493
10	20	0.4	10	42.32	1.185	0.518
10	20	0.6	2	51.64	0.972	0.443
10	20	0.6	3	47.25	1.037	0.469
10	20	0.6	4	44.83	1.113	0.500
10	20	0.6	6	42.27	1.185	0.527
10	20	0.6	8	40.69	1.237	0.547
10	20	0.6	10	39.01	1.241	0.546
10	20	0.8	2	49.63	0.997	0.458
10	20	0.8	3	46.74	1.108	0.504
10	20	0.8	4	43.65	1.152	0.521
10	20	0.8	6	39.61	1.303	0.587
10	20	0.8	8	38.11	1.305	0.583
10	20	0.8	10	37.10	1.333	0.591
10	20	1.0	2	48.68	1.016	0.468
10	20	1.0	3	45.88	1.153	0.528
10	20	1.0	4	41.71	1.237	0.564
10	20	1.0	6	38.01	1.373	0.623
10	20	1.0	8	36.55	1.389	0.624
10	20	1.0	10	34.94	1.450	0.650
20	1	2.0	2	73.92	0.347	0.132
20	1	2.0	3	67.25	0.411	0.159
20	1	2.0	4	61.20	0.410	0.155
20	1	2.0	6	55.43	0.498	0.190
20	1	2.0	8	56.13	0.538	0.205
20	1	2.0	10	49.66	0.579	0.222
20	2	2.0	2	71.26	0.537	0.231
20	2	2.0	3	67.32	0.567	0.236
20	2	2.0	4	61.38	0.568	0.234
20	2	2.0	6	53.69	0.644	0.262
20	2	2.0	8	49.91	0.657	0.265
20	2	2.0	10	47.51	0.675	0.270
20	4	2.0	2	60.47	0.834	0.378
20	4	2.0	3	59.60	0.834	0.371
20	4	2.0	4	56.83	0.864	0.380
20	4	2.0	6	52.10	0.856	0.366
20	4	2.0	8	48.81	0.854	0.361
20	4	2.0	10	45.05	0.827	0.344
20	6	2.0	2	54.38	1.015	0.471
20	6	2.0	3	52.79	1.027	0.467
20	6	2.0	4	51.88	1.095	0.496
20	6	2.0	6	49.55	1.028	0.455
20	6	2.0	8	47.48	1.011	0.443

Continua nella pagina successiva...

Tabella 1 – continua dalla pagina precedente

DL (%)	BS	BT	Arr. Rate (req/sec)	Succ. Rate (%)	Resp. Time (ms)	Exec. Time (ms)
20	6	2.0	10	43.86	0.974	0.418
20	8	2.0	2	50.41	1.106	0.515
20	8	2.0	3	47.84	1.159	0.534
20	8	2.0	4	46.24	1.196	0.547
20	8	2.0	6	46.86	1.238	0.557
20	8	2.0	8	45.50	1.169	0.517
20	8	2.0	10	45.20	1.149	0.503
20	10	2.0	2	51.41	1.184	0.554
20	10	2.0	3	44.67	1.255	0.582
20	10	2.0	4	42.07	1.308	0.603
20	10	2.0	6	42.60	1.413	0.644
20	10	2.0	8	44.37	1.385	0.623
20	10	2.0	10	43.83	1.338	0.595
20	20	0.0	2	93.18	0.408	0.149
20	20	0.0	3	92.22	0.424	0.150
20	20	0.0	4	91.42	0.449	0.158
20	20	0.0	6	75.48	0.524	0.187
20	20	0.0	8	57.08	0.589	0.216
20	20	0.0	10	43.94	0.646	0.241
20	20	0.05	2	77.31	0.518	0.206
20	20	0.05	3	73.65	0.553	0.219
20	20	0.05	4	72.22	0.597	0.235
20	20	0.05	6	69.61	0.641	0.250
20	20	0.05	8	57.28	0.695	0.271
20	20	0.05	10	44.91	0.745	0.291
20	20	0.1	2	68.22	0.602	0.251
20	20	0.1	3	65.10	0.650	0.268
20	20	0.1	4	63.26	0.688	0.282
20	20	0.1	6	60.88	0.750	0.304
20	20	0.1	8	56.31	0.774	0.312
20	20	0.1	10	44.90	0.831	0.336
20	20	0.2	2	59.23	0.719	0.314
20	20	0.2	3	56.47	0.758	0.325
20	20	0.2	4	54.13	0.802	0.341
20	20	0.2	6	51.61	0.854	0.359
20	20	0.2	8	51.20	0.890	0.373
20	20	0.2	10	45.44	0.939	0.392
20	20	0.4	2	53.56	0.807	0.359
20	20	0.4	3	50.22	0.898	0.397
20	20	0.4	4	48.30	0.946	0.416
20	20	0.4	6	46.47	1.028	0.447
20	20	0.4	8	45.12	1.054	0.457
20	20	0.4	10	44.14	1.062	0.456

Continua nella pagina successiva...

Tabella 1 – continua dalla pagina precedente

DL (%)	BS	BT	Arr. Rate (req/sec)	Succ. Rate (%)	Resp. Time (ms)	Exec. Time (ms)
20	20	0.6	2	52.03	0.920	0.418
20	20	0.6	3	48.10	0.954	0.428
20	20	0.6	4	45.20	1.024	0.456
20	20	0.6	6	43.23	1.121	0.496
20	20	0.6	8	41.38	1.154	0.507
20	20	0.6	10	39.53	1.164	0.508
20	20	0.8	2	51.27	0.975	0.448
20	20	0.8	3	46.99	1.042	0.472
20	20	0.8	4	44.39	1.121	0.506
20	20	0.8	6	40.08	1.209	0.542
20	20	0.8	8	38.53	1.242	0.551
20	20	0.8	10	36.95	1.308	0.578
20	20	1.0	2	50.12	0.988	0.456
20	20	1.0	3	47.44	1.132	0.518
20	20	1.0	4	42.89	1.124	0.510
20	20	1.0	6	39.29	1.227	0.550
20	20	1.0	8	37.33	1.366	0.613
20	20	1.0	10	35.33	1.389	0.620
30	1	2.0	2	73.06	0.330	0.125
30	1	2.0	3	65.72	0.366	0.139
30	1	2.0	4	60.71	0.408	0.154
30	1	2.0	6	51.71	0.470	0.179
30	1	2.0	8	50.93	0.516	0.197
30	1	2.0	10	42.98	0.543	0.206
30	2	2.0	2	71.14	0.526	0.224
30	2	2.0	3	65.64	0.541	0.226
30	2	2.0	4	59.43	0.536	0.219
30	2	2.0	6	50.42	0.591	0.238
30	2	2.0	8	48.23	0.602	0.238
30	2	2.0	10	44.80	0.624	0.245
30	4	2.0	2	60.84	0.855	0.389
30	4	2.0	3	59.53	0.802	0.356
30	4	2.0	4	57.20	0.820	0.358
30	4	2.0	6	48.89	0.793	0.337
30	4	2.0	8	46.51	0.765	0.319
30	4	2.0	10	42.96	0.776	0.321
30	6	2.0	2	55.52	1.001	0.464
30	6	2.0	3	54.21	1.033	0.471
30	6	2.0	4	52.30	1.056	0.479
30	6	2.0	6	47.88	0.995	0.439
30	6	2.0	8	45.93	0.933	0.405
30	6	2.0	10	41.85	0.922	0.395
30	8	2.0	2	53.65	1.136	0.530

Continua nella pagina successiva...

Tabella 1 – continua dalla pagina precedente

DL (%)	BS	BT	Arr. Rate (req/sec)	Succ. Rate (%)	Resp. Time (ms)	Exec. Time (ms)
30	8	2.0	3	48.95	1.194	0.552
30	8	2.0	4	47.19	1.201	0.550
30	8	2.0	6	46.92	1.237	0.558
30	8	2.0	8	45.80	1.153	0.511
30	8	2.0	10	42.65	1.104	0.483
30	10	2.0	2	53.17	1.178	0.553
30	10	2.0	3	47.19	1.321	0.615
30	10	2.0	4	44.30	1.357	0.629
30	10	2.0	6	44.05	1.401	0.638
30	10	2.0	8	43.39	1.336	0.601
30	10	2.0	10	42.56	1.311	0.583
30	20	0.0	2	92.23	0.367	0.130
30	20	0.0	3	92.05	0.371	0.125
30	20	0.0	4	90.69	0.410	0.140
30	20	0.0	6	83.72	0.472	0.163
30	20	0.0	8	62.42	0.524	0.184
30	20	0.0	10	46.83	0.603	0.220
30	20	0.05	2	78.28	0.464	0.181
30	20	0.05	3	74.51	0.502	0.193
30	20	0.05	4	72.97	0.543	0.209
30	20	0.05	6	70.32	0.599	0.229
30	20	0.05	8	62.37	0.632	0.241
30	20	0.05	10	47.35	0.687	0.263
30	20	0.1	2	70.58	0.536	0.219
30	20	0.1	3	65.79	0.587	0.239
30	20	0.1	4	64.64	0.622	0.251
30	20	0.1	6	62.66	0.675	0.268
30	20	0.1	8	60.30	0.700	0.276
30	20	0.1	10	48.34	0.754	0.298
30	20	0.2	2	60.58	0.646	0.276
30	20	0.2	3	57.86	0.701	0.297
30	20	0.2	4	56.28	0.741	0.312
30	20	0.2	6	53.42	0.797	0.331
30	20	0.2	8	52.83	0.826	0.342
30	20	0.2	10	49.07	0.853	0.350
30	20	0.4	2	54.78	0.775	0.344
30	20	0.4	3	50.98	0.811	0.355
30	20	0.4	4	49.38	0.869	0.378
30	20	0.4	6	46.91	0.952	0.411
30	20	0.4	8	45.51	0.981	0.420
30	20	0.4	10	44.19	0.992	0.422
30	20	0.6	2	52.26	0.837	0.379
30	20	0.6	3	48.90	0.918	0.409
30	20	0.6	4	46.83	0.959	0.425

Continua nella pagina successiva...

Tabella 1 – continua dalla pagina precedente

DL (%)	BS	BT	Arr. Rate (req/sec)	Succ. Rate (%)	Resp. Time (ms)	Exec. Time (ms)
30	20	0.6	6	43.06	1.022	0.448
30	20	0.6	8	41.66	1.090	0.476
30	20	0.6	10	39.77	1.122	0.487
30	20	0.8	2	51.89	0.884	0.401
30	20	0.8	3	47.83	0.986	0.444
30	20	0.8	4	45.20	1.049	0.471
30	20	0.8	6	40.83	1.122	0.499
30	20	0.8	8	38.71	1.192	0.527
30	20	0.8	10	37.31	1.232	0.541
30	20	1.0	2	51.66	0.964	0.444
30	20	1.0	3	46.83	0.994	0.451
30	20	1.0	4	43.39	1.077	0.487
30	20	1.0	6	38.47	1.192	0.534
30	20	1.0	8	36.89	1.319	0.590
30	20	1.0	10	35.05	1.384	0.619