

Analisi delle Prestazioni di Modelli Centralizzati ILP per il Task Routing al variare della Deadline

Claudio Bagini 2045337

September 7, 2026

Il presente documento sintetizza i risultati della campagna sperimentale condotta sull'orchestratore centralizzato ILP, valutando l'esplorazione esaustiva dei parametri di batching ($BS \in \{1, \dots, 20\}$, $BT \in [0.0, 2.0]$ s) e di instradamento topologico. I grafici sono strutturati per metrica di riferimento — tasso di successo (*Success Rate*), distribuzione delle cause di rigetto (*Rejection Causes*) e scomposizione del tempo di risposta (*Stacked Response Time*) — e confrontano sistematicamente le prestazioni al variare del carico di traffico ($\lambda \in [2, 10]$ req/s), della tolleranza temporale ($\Delta D \in \{10\%, 20\%, 30\%\}$) e dell'obiettivo di allocazione adottato (*Energy Mapping* rispetto a *Time Mapping*).

Task Success Rate — Energy Mapping ($w_{lat} = 0, w_{en} = 1$)




Figure 1: Success Rate across arrival rates ($\Delta D = 10\%$).




Figure 2: Success Rate across arrival rates ($\Delta D = 20\%$).




Figure 3: Success Rate across arrival rates ($\Delta D = 30\%$).

Task Success Rate — Time Mapping ($w_{lat} = 1, w_{en} = 0$)




Figure 4: Success Rate across arrival rates ($\Delta D = 10\%$).




Figure 5: Success Rate across arrival rates ($\Delta D = 20\%$).




Figure 6: Success Rate across arrival rates ($\Delta D = 30\%$).

L'analisi del tasso di successo evidenzia come il parametro determinante non sia l'obiettivo di mapping, bensì la gestione del batching: la configurazione $BS = 20$ con $BT = 0.0$ s (in particolare con Dijkstra Energy) registra le prestazioni più elevate, superando il 90% di completamento a basso carico. All'aumentare dell'arrival rate ($\lambda \rightarrow 10$ req/s), tutte le configurazioni subiscono un degrado prestazionale; tuttavia, timeout di aggregazione elevati ($BT \geq 0.4$ s) o batch ampi con attesa prolungata ($BS = 10, BT = 2$ s) penalizzano drasticamente il sistema già a carichi moderati, mentre il rilassamento della deadline (ΔD) produce incrementi marginali.

Failure Causes Distribution — Energy Mapping ($w_{lat} = 0, w_{en} = 1$)




Figure 7: Failure Causes breakdown across arrival rates ($\Delta D = 10\%$).




Figure 8: Failure Causes breakdown across arrival rates ($\Delta D = 20\%$).




Figure 9: Failure Causes breakdown across arrival rates ($\Delta D = 30\%$).

Failure Causes Distribution — Time Mapping ($w_{lat} = 1, w_{en} = 0$)




Figure 10: Failure Causes breakdown across arrival rates ($\Delta D = 10\%$).




Figure 11: Failure Causes breakdown across arrival rates ($\Delta D = 20\%$).




Figure 12: Failure Causes breakdown across arrival rates ($\Delta D = 30\%$).

La distribuzione delle cause di fallimento rivela una marcata polarizzazione architetturale: nelle configurazioni con inoltro immediato ($BT \leq 0.05$ s o $BS = 1$), i rigetti sono dovuti quasi esclusivamente all'esaurimento della capacità di calcolo (*Insuff. CPU*) e banda (*Insuff. CPU+NET*). Al contrario, all'aumentare del timeout di batching ($BT > 0.1$ s), l'attesa in coda divora il budget temporale dei task, rendendo la violazione di scadenza (*Deadline Exceeded*) responsabile del 70–85% delle reiezioni totali. L'incremento del carico λ intensifica progressivamente la saturazione fisica dei nodi.

Stacked Response Time Breakdown — Energy Mapping ($w_{lat} = 0, w_{en} = 1$)




Figure 13: Stacked Response Time across arrival rates ($\Delta D = 10\%$).




Figure 14: Stacked Response Time across arrival rates ($\Delta D = 20\%$).




Figure 15: Stacked Response Time across arrival rates ($\Delta D = 30\%$).

Stacked Response Time Breakdown — Time Mapping ($w_{lat} = 1, w_{en} = 0$)




Figure 16: Stacked Response Time across arrival rates ($\Delta D = 10\%$).




Figure 17: Stacked Response Time across arrival rates ($\Delta D = 20\%$).




Figure 18: Stacked Response Time across arrival rates ($\Delta D = 30\%$).

La scomposizione del tempo di risposta mostra chiaramente come il tempo di calcolo effettivo del sistema (*System Execution*, porzione solida inferiore) si mantenga ridotto e pressoché invariato ($\approx 0.2\text{--}0.7$ ms) attraverso tutte le configurazioni. La latenza end-to-end è interamente dominata dalla componente di accodamento e rete (*Network/Wait Time*, porzione trasparente superiore), la quale scala in modo proporzionale a BT e ad λ . Il *Time Mapping* apporta solo una lievissima contrazione della latenza di rete rispetto all'*Energy Mapping*, confermando che il disaccoppiamento temporale introdotto dal batching sovrasta la funzione obiettivo del solutore.